

所做研究: 1. 3个预训练模型内部在不同窗口大小下, 模型泛化能力的比较. → 找出最适合 model 的窗口.

不仅看 nt-level
也要看组装水平

2. 在同-窗口大小下, 不同预训练模型的性能比较 → 找出最好的 model → 一个 benchmark

3. 完成 1 的前提是对不同物种 TE 的长度做一个可视化, 探究这种内在关联性.

可以思考将
输出直接调
整为 TE-family

4. 选定好一个 model 之后, 可以开始做更详细的研究, 包括: 提取 pre-trained 的泛化应用路线.

(1) 这个 model 在不同物种 fine-tune 后的泛化能力. 以及 TE 家族比较的相关指标

① no-human: 看这些反义泛化于人类的可靠性

② animals: 看 animals 内部泛化力和应用于 plant 的能力.

③ animals + plants: 查看多了 plants 是否会改善 animals 的, 以及对于 plants 本身的改进.

④ animals + plants + fungi:

⑤ fungi-only 和 plants-only

(2) 基于泛化能力的衰减, 我们基于相关因素来构建泛化性衰减公式:

① TE 组成相似度

② 遗传距离.

③ ... (与 AI 多沟通, 并且可查看是否有相关的这种公式的推导研究).

(3) 对于碎片化 TE 的组装能力评估判断:

存在的一个极大的问题就是, 许多 CLM 会将零星的小片段标注为 TE.

需要做一个严格的过滤和筛选, 包括但不限于:

① 学习 Segment TE 等工具的处理

② 加入 CRF, HMM 等层来平滑输出.

③ 使用启发式方案, 例如至少要有 50 bp 的 TE 注释才被标注.

④ ... (其他更多的方案)

(4) 构建一个基于 pre-trained model embedding 的 TE-family cluster.

① 使用无监督的聚类方式 + 对比学习

② 使用 fine-tuned 前后的 embedding 作对比.

③ 尝试一下可解释性方向的研究.

5. 最后构建好一款可用的 model 后 (可能可以跨 kingdom, 也可能是更为特异性的),

我们开始专注于和传统生信工具作一个系统的对比 (选择 5 款左右即可).

6. 一直想尝试的一个研究是 PU-Learning, 但是发现效果并不好. 所有的出发点都是基于当前的注释就是专注于已有的注释结果. 但其因组中必然有 TE 的遗漏, 但我们的却无法判定我们的结果是 TP, 还是 ~~FP~~ TP?

→ 两条思路: ① 延续 hg19 训练, 得到的 positive 高分片段投射于 hg38. hsl. 与更新后的注释结果比较.

② no-human 训练的结果在 human 上的评分作为 gold-standard.

与在其余物种上泛化的评分作比较, 看会不会显著更低 (同样遗传距离). 计算 p-value 说明是否差异显著.